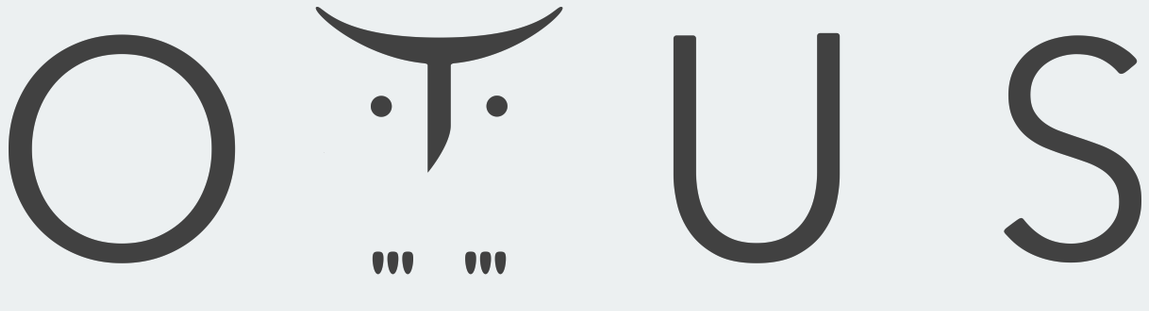

ОНЛАЙН-ОБРАЗОВАНИЕ

OTUS

Основы контейнеризации в Linux

namespaces & cgroups

Александр Румянцев

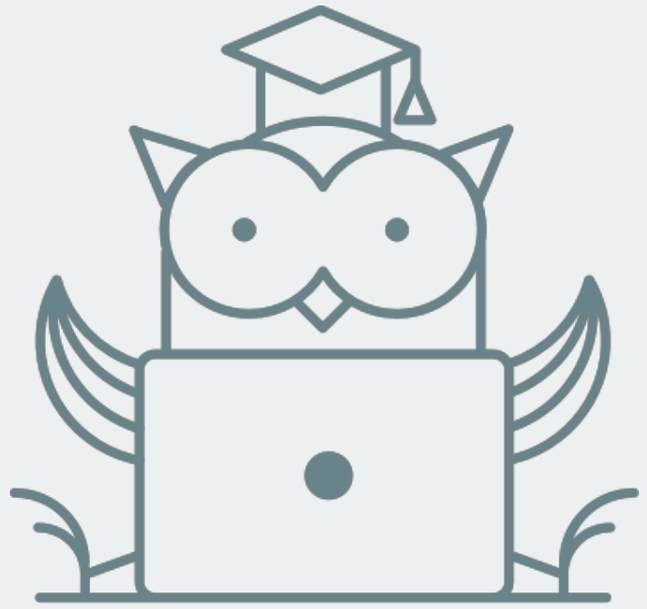

Для чего нужна контейнеризация?

Для чего нужна контейнеризация?

- **Разделение ресурсов сервера**
- **Песочница для критичных сервисов**
- **Запуск нескольких одинаковых сервисов при унификации управления**
- **Разделение доступа и предоставление полного окружения разным непривилегированным пользователям**

Первые механизмы. Шаг 1.

chroot - подмена корня файловой системы для группы процессов

Появился в 1979 году в AT&T Version 7 Unix, а в 1982 - в 4.2BSD

Недостатки:

- **пространство процессов общее**
- **сеть общая**
- **отсутствие ограничения ресурсов**

Фактически служит для целей изоляции процессов (например, до сих пор bind опционально штатно во многих дистрибутивах запускается в chroot, многие демоны перед понижением привилегий делают chroot в пустую директорию) или пользователей (chroot используется, например в демоне ftp, ограничивая анонимного пользователя

Разработчики и пользователи IBM S/390 смотрят с насмешкой

Первые механизмы. Шаг 2.

jail - первые контейнеры в FreeBSD
Появились в 1999-2000 годах в FreeBSD 4.0

Достоинства:

- **изоляция сети (но нет изоляции loopback)**
- **некоторая изоляция процессов**

Недостатки:

- **отсутствие ограничения ресурсов**

openvz - первое появление в 2000 году, до прода дошло уже в 2.6, примерно в 2002 году, сложная судьба из-за неудачных попыток коммерциализации

Разработчики и пользователи IBM S/390 смотрят с удивлением
Разработчики (они же пользователи) Plan9 смотрят с грустью

Time to pivot(). Namespaces.

Все механизмы обладали одним недостатком: это были костыли и палки, проросшие глубоко в ядро. В какой-то момент это осознали и в 2002 году, в ядре 2.4.19 появился Namespaces API, состоящий из трех системных функций:

- **clone (2) - аналог fork()**
- **setns (2) - подключение к namespace существующего процесса**
- **unshare (2) - изменение контекста текущего приложения**

которые доступны пользователю с привилегиями CAP_SYS_ADMIN, или, проще говоря, root.

Namespace - новый атрибут процесса

Namespace

Абстракция над общими ресурсами, позволяющая разным процессам иметь разное представление о тех глобальных ресурсах, которыми они распоряжаются

На данный момент существуют следущие пространства имён (`man 7 namespaces`):

`Cgroup` - используется как атрибут, корневой узел дерева cgroup
`IPC` - IPC
`Network` - сетевой стек: интерфейсы, таблицы маршрутизации, etc
`Mount` - (CLONE_NEWNS, xe-xe) - аналог chroot
`PID` - пространство номеров процессов
`User` - пространство пользователей
`UTS` - изолированный hostname и NIS domain name

Утилиты для работы с namespaces

- **unshare (1) - запуск процесса в новом namespace**
- **nsenter (1) - подключение к namespace существующего процесса**
- **/proc/<pid>/ns/**

Mount namespace

Можно разделять общие каталоги, классический пример в до-systemd эпоху - изоляция /tmp (в systemd уже есть параметр PrivateTmp)

Chroot делается в mount namespace через `mount -o bind` или `pivot_root`

Network Namespace

Можно уже делать свои контейнеры. Но лучше - использовать разные таблицы маршрутизации для разных процессов.

```
root@host:/# ip link add veth0 type veth peer name veth1
root@host:/# ip link set veth1 netns netns1
root@host:/# ip addr add 172.16.99.1/24 dev veth0
root@host:/# ip link set veth0 up
root@host:/# ip netns exec netns1 ip addr add 172.16.99.100/24 dev veth1
root@host:/# ip netns exec netns1 ip link set lo up
root@host:/# ip netns exec netns1 ip link set veth1 up
root@host:/# ip netns exec netns1 ip route add default via 172.16.99.1
```


User & PID namespaces

Уже появились сильно позже конкретно для контейнеров

User Namespace, позволяет иметь к каждом контейнере своих системных пользователей, включая рута. А через механизм subuid (5) можно сопоставить непривилегированных пользователей хост системы с root контейнера.

Pid Namespace - тот же смысл, позволяет в каждом контейнере иметь свою систему инициализации с PID=1, а так же полностью изолированные процессы (процессы, не входящие в namespace не "видны")

/etc/subuid и /etc/subgid - конфигурация для выделения отдельного пространства идентификаторов

Ну всё, можно делить машину на контейнеры. Oh wa...

Но тут контейнеры начинают мечтать обо всех доступных ресурсах системы

Вначале было слово

Словом было - process accounting, появившийся давно (1999 год), но сильно расширенный в ядре 2.6.20 (2007 год) параллельно с появлением KVM (совпадение? не думаю!) - подсистема, позволившая вести учёт ресурсов по каждому процессу, которой мы пользуемся в atop/sar со своей админской стороны. Ну а основы социализма нам говорят, что кроме учета должен быть и контроль.

Примерно тогда же в 2006 году внутри Google началась разработка process containers с усовершенствования механизма cpuset, который позволял ограничить процессы по времени исполнения.

control groups

Подсистема ядра, позволяющая создавать иерархические группы процессов, каждая из которых обладает своим набором счётчиков.

В корне иерархии (дерева) - набор контроллеров для учёта и контроля групп.

Процесс может принадлежать разным группам под разными контроллерами, но не может быть в разных ветвях одного контроллера (при этом он будет в группе верхней иерархии)

systemd имеет свою ветку, не имеющую контроллера задачей которого является просто группировка процессов. Главный процесс заносится в новую группу, а потомки (см слайд "порождение процессов") появляются в той-же группе. Это позволяет управлять сервисом без знания PID главного процесса и не оставляя неприкаяных демонов. При завершении всех процессов в группе systemd об этом уведомляется.

Контроллеры

в CentOS 7 мы имеем:

blkio: управление доступной полосой при доступе к блочным устройствам
cpu: управление доступом к ресурсам процессора
cpuacct: аккаунтинг cpu; используется совместно с контроллером cpu
cpuset: выделение отдельных процессоров группе
devices: ограничение доступа к устройствам
freezer: заморозка процессов (спасибо команде OpenVZ)
memory: ограничение памяти для группы
net_cls: шейпинг (man 8 tc)
perf_event: интерфейс для perf
hugetlb: ограничение работы с huge pages
pid: ограничение числа процессов

Интерфейс

В отличие от namespaces, cgroups имеет простой интерфейс для управления. Он реализован в виде псевдо-FS cgroup

Для того, что бы начать использовать cgroups, нужно смонтировать вершину иерархии в любой каталог, в качестве опции передав имена контроллеров, которые будут обслуживать иерархию.

В CentOS 7 все возможные контроллеры смонтированы под `/sys/fs/cgroup/`

Основные файлы

`/proc/<pid>/cgroup` (read only) — список групп к которым принадлежит процесс

Иерархия `/sys/fs/cgroup/*`
`cgroup.clone_children` — позволяет передавать дочерним контрольным группам свойства родительских
`tasks` — содержит список PID всех процессов, включённых в контрольные группы
`cgroup.procs` — содержит список TGID групп процессов, включённых в контрольные группы
`cgroup.event_control` — позволяет отправлять уведомления в случае изменения статуса контрольной группы
`release_agent` — содержится команда, которая будет выполнена, если включена опция notify_on_release. Может использоваться, например, для автоматического удаления пустых контрольных групп
`notify_on_release` — содержит булеву переменную (0 или 1), включающую (или наоборот отключающую), выполнение команду, указанной в release_agent.

Недостатки

Разные контроллеры разрабатывались разными группами людей, в результате:

- **мы имеем несколько иерархий**
- **в одних и тех же подсистемах ядра присутствуют части разных контроллеров**
- **разные контроллеры по-разному понимают наследование групп**

Отдельный анекдот: процесс, ограниченный по памяти продолжает видеть в /proc/meminfo всю доступную память, что иногда приводит к казусам. Решается с помощью псевдо-ФС lxcfs из комплекта LXC

До основания, а затем

С 2015 года разрабатывается cgroups v2, (присутствует в ядре начиная с версии 4.5) которая представляет единую иерархию, в которой контроллеры на лету добавляются в группу.

Но пока там всего три контроллера: blkio, memory и PID, а также начальная поддержка cpuset

Ждем, надеемся, верим.

Зачем это всё

Все системы (lxc, docker, rkt, много их нынче развелось) контейнеризации используют только описанные механизмы.
Не все системы контейнеризации предоставляют нужные функции, особенно мониторинга, динамического ограничения ресурсов etc.

В любой контейнер вы можете зайти с помощью nsenter вне зависимости от используемой системы.

Любой контейнер вы можете дополнительно промониторить или ограничить вне зависимости от используемой системы.

Бонус

Контейнеризация из коробки в три шага: systemd-nspawn

1. **Готовим образ**
   ```
   yum --installroot=/var/lib/machines/test --releasever=7 -y install centos-
   release systemd passwd yum iproute
   :> /var/lib/machines/test/etc/sysconfig/network
   echo -e 'pts/0\npts/1\npts/2\n' >> /var/lib/machines/test/etc/securetty
   chroot /var/lib/machines/test passwd
   ```
2. **Включаем сервис**
   ```
   machinectl enable test
   ```
3. **Запускаем машину**
   ```
   machinectl start test
   ```
4. **Логинимся**
   ```
   machinectl login test
   ```


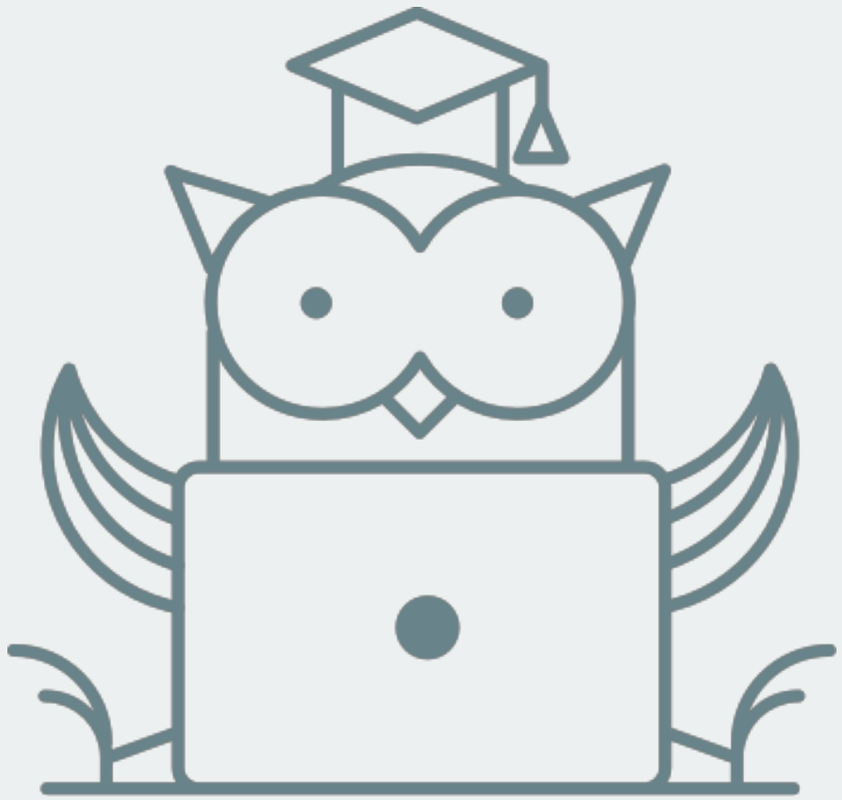

Спасибо
за внимание!

Вопросы?